在预条件化空间累积动量的单机 STP-Adam

候选算法、完整公式对照与相关噪声矩阵设计

本文对比原版 STP-Adam、最初候选算法与调整后的自适应 α 算法。候选算法在预条件空间累积一阶动量并直接更新参数；自适应版本根据历史二阶能量选择恢复指数，再用部分恢复后的查询更新二阶状态。三列均采用逐样本缩放裁剪与单路相关噪声。

1 记号与相关噪声

第 t 轮在参数 x^{t-1} 上计算单样本梯度 $g^t = \nabla \ell(x^{t-1}; z)$。尖括号 $\langle\cdot\rangle$ 表示当前 batch 平均。所有向量乘除、平方和平方根均逐坐标进行；裁剪根据整个向量的欧氏范数计算：

$$\mathrm{clip}(a; R) = a \min\left\{1, \frac{R}{\|a\|_2}\right\}, \qquad \mathrm{clip}(0; R) = 0.$$

设 C 为训练前确定的可逆下三角矩阵，独立高斯向量 $\xi^1, \ldots, \xi^T$ 构成矩阵 Ξ。本轮相关噪声为

$$Z^t = [C^{-1}\Xi]^\top_{t,:} = \sum_{k=1}^{t} (C^{-1})_{t,k} \xi^k.$$

采用增删邻接：公开样本槽位与参与安排固定，删除的样本由零贡献空槽替代，batch 分母始终为固定的 b。单步裁剪平均的变化至多为 R/b。噪声幅度需要结合 C、裁剪半径 R、batch size 和数据参与约束校准。为统一比较，预缩放和最终更新使用相同稳定常数 $\epsilon_s > 0$。

2 与原版 STP-Adam 的完整对照

红色标出候选算法及自适应 α 的改动。原版的一阶动量 m^t 处于梯度尺度，两种候选的一阶动量 u^t 处于预条件尺度。动量和二阶状态均与参数同形；α^t 是每轮一个标量。

原版 STP-Adam	最初候选算法	自适应 α（调整后）
$m^0 = v^0 = 0$	$u^0 = v^0 = 0$	$u^0 = v^0 = \hat{v}^0 = 0$
$d^0 = \epsilon_s \mathbf{1}$	$d^0 = \epsilon_s \mathbf{1}$	$d^0 = \mathbf{1}$
$q^t = \left\langle \mathrm{clip}\left(\frac{g^t}{d^{t-1}}; R\right)\right\rangle$	$q^t = \left\langle \mathrm{clip}\left(\frac{g^t}{d^{t-1}}; R\right)\right\rangle$	$q^t = \left\langle \mathrm{clip}\left(\frac{g^t}{d^{t-1}}; R\right)\right\rangle$
$\tilde{q}^t = q^t + Z^t$	$\tilde{q}^t = q^t + Z^t$	$\tilde{q}^t = q^t + Z^t$
—	—	$\alpha^t = \max(\mathcal{F}^t \cup \{0\})$
$\tilde{g}^t = d^{t-1} \odot \tilde{q}^t$	$\tilde{g}^t = d^{t-1} \odot \tilde{q}^t$	$r^t = r^t(\alpha^t)$
$m^t = \beta_1 m^{t-1} + (1-\beta_1)\tilde{g}^t$	$u^t = \beta_1 u^{t-1} + (1-\beta_1)\tilde{q}^t$	$u^t = \beta_1 u^{t-1} + (1-\beta_1)\tilde{q}^t$
$\hat{m}^t = \frac{m^t}{1-\beta_1^t}$	$\hat{u}^t = \frac{u^t}{1-\beta_1^t}$	$\hat{u}^t = \frac{u^t}{1-\beta_1^t}$
$v^t = \beta_2 v^{t-1} + (1-\beta_2)(\tilde{g}^t)^2$	$v^t = \beta_2 v^{t-1} + (1-\beta_2)(\tilde{g}^t)^2$	$v^t = \beta_2 v^{t-1} + (1-\beta_2)(r^t)^2$
$\hat{v}^t = \frac{v^t}{1-\beta_2^t}$	$\hat{v}^t = \frac{v^t}{1-\beta_2^t}$	$\hat{v}^t = \frac{v^t}{1-\beta_2^t}$
$d^t = \sqrt{\hat{v}^t} + \epsilon_s$	$d^t = \sqrt{\hat{v}^t} + \epsilon_s$	$d^t = \sqrt{\hat{v}^t} + \epsilon_s$
$x^t = x^{t-1} - \eta \frac{\hat{m}^t}{d^t}$	$x^t = x^{t-1} - \eta \hat{u}^t$	$x^t = x^{t-1} - \eta \hat{u}^t$

第三列每轮根据当前查询重新计算一个标量 α^t，按以下顺序执行。

第一步：算出本轮的能量参照和试算公式。先将旧的偏差修正二阶状态相加，得到本轮参照 M；再定义试用指数 a 对应的恢复向量及其能量：

$$M = \mathbf{1}^\top \hat{v}^{t-1}, \qquad c^t = \max\{1, \|d^{t-1}\|_\infty\},$$

$$r^t(a) = c^t \left(\frac{d^{t-1}}{c^t}\right)^a \odot \tilde{q}^t, \qquad E(a) = \|r^t(a)\|_2^2, \qquad a \in [0, 1].$$

c^t 直接由旧分母计算，无需选择新参数；幂运算逐坐标进行。$E(a)$ 随 a 单调不增，因此能量不足时向更小的 a 搜索。表中的 $\mathcal{F}^t = \{a \in [0,1] : E(a) \geq M\}$ 表示能量达标的指数。本轮在能量达标的指数中尽量取大的值，以接近完全恢复。

第二步：先试两个端点。先算 $E(1)$：若 $E(1) \geq M$，直接取 $\alpha^t = 1$，此时 $r^t = d^{t-1} \odot \tilde{q}^t$。若 $E(1) < M$，再算 $E(0)$：若连 $E(0) < M$，则取 $\alpha^t = 0$；否则，所需指数位于 $[0,1]$ 内，进入下一步。

第三步：二分找到最大的达标指数。初始化下界 $L = 0$、上界 $U = 1$，重复 24 次：

$$a = \frac{L+U}{2}, \qquad \begin{cases} L \leftarrow a, & E(a) \geq M \quad \text{（达标，继续试更大的指数）}, \\ U \leftarrow a, & E(a) < M \quad \text{（不足，改试更小的指数）}. \end{cases}$$

最后取 $\alpha^t = \max\{0, L - 10^{-6}\}$，微小回退保持可行。计算 $r^t = r^t(\alpha^t)$，再按表更新 $v^t, \hat{v}^t, d^t$。下一轮重新计算 $M, E(a)$ 并搜索 α^{t+1}；当前轮的一阶动量和参数更新仍直接使用 $\tilde{q}^t$。

一维例子。忽略极小稳定项，取同一历史状态 $d^{t-1} = 1/4$、$\hat{v}^{t-1} = 1/16$，当前查询为 $\tilde{q}^t = 1/2$。此时 $c^t = 1$，所以

$$M = \frac{1}{16}, \qquad r^t(a) = \left(\frac{1}{4}\right)^a \frac{1}{2}, \qquad E(a) = \left(\frac{1}{4}\right)^{2a} \left(\frac{1}{2}\right)^2.$$

试用指数 a	恢复后的能量 $E(a)$	判断与动作
1	$(\frac{1}{4})^2(\frac{1}{2})^2 = \frac{1}{64}$	小于 M，减小指数
0	$(\frac{1}{4})^0(\frac{1}{2})^2 = \frac{1}{4}$	大于 M，可以二分
$\frac{1}{2}$	$(\frac{1}{4})^1(\frac{1}{2})^2 = \frac{1}{16}$	等于 M，下界改为 $1/2$
$\frac{3}{4}$	$(\frac{1}{4})^{3/2}(\frac{1}{2})^2 = \frac{1}{32}$	小于 M，上界改为 $3/4$

继续二分后得到 $\alpha^t \approx 1/2$：完全恢复时能量不足，减小指数后补到了参照值。若在同一历史状态下当前查询改为 1，则 $E(1) = 1/16$，直接取 $\alpha^t = 1$；若改为 $1/8$，则 $E(0) = 1/64 < M$，取 $\alpha^t = 0$。因此，指数由当前查询与历史尺度共同决定，可随迭代增大或减小。整个选择只使用 $\tilde{q}^t$ 和历史状态，仍保留阈值 R 与一路蓝色噪声 Z^t。

记当前 batch 中的单样本梯度为 $g_i^t = \nabla \ell(x^{t-1}; z_i)$，batch size 为 b。表中的平均具体展开为

$$q^t = \frac{1}{b}\left[\text{clip}\left(\frac{g_1^t}{d^{t-1}}; R\right) + \cdots + \text{clip}\left(\frac{g_b^t}{d^{t-1}}; R\right)\right].$$

与原稿一样，先逐样本裁剪，再取 batch 平均。这里每个样本先除以同一个历史尺度 d^{t-1}，再对缩放后的整个梯度向量分别裁剪；平均完成后才加入 Z^t。

以下统一讨论对比表第三列的自适应 α 算法。

3 自适应状态与参数更新

α^t 调节二阶输入，再由新分母影响下一轮查询：

$$\tilde{q}^t \longrightarrow (\alpha^t, r^t) \longrightarrow (v^t, d^t) \longrightarrow q^{t+1}.$$

参数方向仍由 $\tilde{q}^t$ 的一阶动量决定。预处理已发生在查询中：令 $\beta_1 = 0$，去掉裁剪和噪声观察其尺度，有

$$x^t = x^{t-1} - \eta \frac{\bar{g}^t}{d^{t-1}},$$

其中 $\bar{g}^t$ 为 batch 平均梯度，新分母 d^t 从下一轮使用。例如 $\ell(x,y) = 5(x-a)^2 + \frac{1}{2}(y-b)^2$ 的 Hessian 为 $H = \text{diag}(10, 1)$；当 $d^{t-1} \approx (10, 1)$ 时，

$$\frac{g^t}{d^{t-1}} \approx \begin{pmatrix} x^{t-1} - a \\ y^{t-1} - b \end{pmatrix}.$$

因此，自适应性保留在查询的坐标缩放中；α^t 在线调整后续使用的二阶尺度。

4 从参数轨迹得到工作负载与B

固定学习率 η。由一阶动量递推直接展开，

$$\hat{u}^t = \rho^t\big(\tilde{q}^t + \beta_1\tilde{q}^{t-1} + \cdots + \beta_1^{t-1}\tilde{q}^1\big), \qquad \rho^t = \frac{1-\beta_1}{1-\beta_1^t},$$

$$x^t - x^0 = -\eta(\hat{u}^1 + \cdots + \hat{u}^t).$$

每轮输入 $\tilde{q}^t$ 是列向量，转置后占一行；行表示时间，列表示参数坐标。记

$$\widetilde{\mathbf{Q}} = \begin{pmatrix} (\tilde{q}^1)^\top \\ (\tilde{q}^2)^\top \\ (\tilde{q}^3)^\top \\ \vdots \end{pmatrix}, \quad \widehat{U} = \begin{pmatrix} (\hat{u}^1)^\top \\ (\hat{u}^2)^\top \\ (\hat{u}^3)^\top \\ \vdots \end{pmatrix}, \quad X = \begin{pmatrix} (x^1)^\top \\ (x^2)^\top \\ (x^3)^\top \\ \vdots \end{pmatrix}, \quad X^0 = \mathbf{1}_T(x^0)^\top.$$

上述两次累积依次对应

$$A_{\beta_1} = \begin{pmatrix} 1 & 0 & 0 & \cdots \\ \beta_1 & 1 & 0 & \cdots \\ \beta_1^2 & \beta_1 & 1 & \cdots \\ \vdots & \vdots & \ddots & \ddots \end{pmatrix}, \quad D_\rho = \begin{pmatrix} 1 & 0 & 0 & \cdots \\ 0 & \rho^2 & 0 & \cdots \\ 0 & 0 & \rho^3 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}, \quad A_1 = \begin{pmatrix} 1 & 0 & 0 & \cdots \\ 1 & 1 & 0 & \cdots \\ 1 & 1 & 1 & \cdots \\ \vdots & \vdots & \ddots & \ddots \end{pmatrix}.$$

先对历史查询加权并修正动量，再累加参数步长：

$$\widehat{U} = D_\rho A_{\beta_1}\widetilde{\mathbf{Q}}, \qquad X - X^0 = -\eta A_1\widehat{U}.$$

故自适应 α 算法的工作负载为

$$\boxed{A = A_1 D_\rho A_{\beta_1}}, \qquad X - X^0 = -\eta A\widetilde{\mathbf{Q}}.$$

α^t, β_2 通过二阶状态影响查询序列；从 $\tilde{q}^t$ 到参数的线性累积只由 β_1 决定。

将实际查询 q^t 也按行堆叠为 $\mathbf{Q}$。由单路相关噪声定义，

$$\widetilde{\mathbf{Q}} = \mathbf{Q} + C^{-1}\Xi,$$

$$X - X^0 = -\eta A(\mathbf{Q} + C^{-1}\Xi) = -\eta AC^{-1}(C\mathbf{Q} + \Xi).$$

于是

$$\boxed{B = AC^{-1} = A_1 D_\rho A_{\beta_1} C^{-1}}, \qquad BC = A.$$

比较时两侧共用同一实际查询序列 $\mathbf{Q}$，移除显式噪声项得到参考轨迹：

$$X_{\text{ref}} = X^0 - \eta A\mathbf{Q}, \qquad \boxed{\Delta X = X - X_{\text{ref}} = -\eta B\Xi}.$$

这里 $\mathbf{Q}$ 已包含自适应 α 形成的历史缩放。该指标度量显式噪声的累积扰动。若 Ξ 各元素独立服从 $\mathcal{N}(0, \sigma_{\text{DP}}^2)$，则

$$\boxed{\frac{1}{pT}\mathbb{E}\|\Delta X\|_F^2 = \eta^2\sigma_{\text{DP}}^2\frac{\|B\|_F^2}{T}}.$$

5 离线设计C 与噪声方差

固定算法配置及隐私预算 (ε, δ)。T 为训练步数，K 为同一样本两次参与的最小间隔；批次安排与样本内容无关。P 为噪声历史带宽，Q 为缓冲向量个数，默认取 $P = K, Q = 5$。粗体 $\mathbf{Q}$ 表示查询矩阵，整数 Q 表示缓冲数。以下按计算顺序进行，离线迭代编号为 j，训练轮次为 t。

1．固定工作负载和初值。由 T, β_1 一次生成 A_1, D_ρ, A_{β_1}，令 $A = A_1 D_\rho A_{\beta_1}$。两组待优化参数均为 Q 维：

$$\theta^{(0)} = \left(\frac{1}{Q+1}, \ldots, \frac{Q}{Q+1}\right)^\top, \qquad \omega^{(0)} = -\frac{1-\theta^{(0)}}{2Q}.$$

搜索范围保持为

$$0 < \theta_r < 1, \qquad \omega_r < 0, \qquad \theta_r \neq \theta_s\ (r \neq s), \qquad 1 + \mathbf{1}_Q^\top\frac{\omega}{1-\theta} > 0.$$

2．由当前参数生成 C^{-1}。对 $(\theta^{(j)},\omega^{(j)})$，先生成第一列的序列

$$\begin{pmatrix} 1 \\ (\omega^{(j)})^\top \mathbf{1}_Q \\ (\omega^{(j)})^\top \theta^{(j)} \\ (\omega^{(j)})^\top (\theta^{(j)})^2 \\ \vdots \end{pmatrix}.$$

保留前 P 项，其后补零至 T 项；其余列依次向下平移并在顶部补零。θ 的幂均逐元素计算。$P=1$ 时直接取 $C^{-1}=C=I_T$。

3．计算 C、B 和敏感度。 C 用于敏感度，C^{-1} 用于噪声和误差；数值上通过三角线性方程求解：

$$(C^{(j)})^{-1}C^{(j)} = I_T, \qquad B^{(j)} = A(C^{(j)})^{-1}.$$

上述可行域使 C 的 Toeplitz 系数非负递减，K 间隔参与规则下的归一化敏感度为

$$\boxed{\mathrm{Sens}(C^{(j)}) = \left\| C^{(j)}_{:,1} + C^{(j)}_{:,1+K} + C^{(j)}_{:,1+2K} + \cdots \right\|_2}.$$

冒号表示取整列，列号不超过 T。固定历史私有输出时，d^{t-1} 已确定；增删一个参与样本使裁剪平均 q^t 改变至多 R/b。α^t 及二阶状态均由已有私有输出计算，沿用这一查询敏感度。

4．计算本组参数对应的误差目标。相同预算下，噪声方差正比于 $\mathrm{Sens}^2(C)$。将它与参数累积系数相乘，得到

$$\boxed{\mathcal{E}^2(C) = \frac{\|A_1 D_\rho A_{\beta_1} C^{-1}\|_F^2}{T}\,\mathrm{Sens}^2(C)}.$$

记初值对应的误差为 $\mathcal{E}_0^2 = \mathcal{E}^2(\theta^{(0)},\omega^{(0)})$。代码实际最小化归一化障碍目标

$$\boxed{F(\theta,\omega) = \frac{\mathcal{E}^2(\theta,\omega)}{\mathcal{E}_0^2} + 10^{-3}\varphi(\theta,\omega)}.$$

这等价于将未归一化目标中的障碍权重固定为 $\lambda = 10^{-3}\mathcal{E}_0^2$。

$$\begin{aligned}\varphi(\theta,\omega) = &-\mathbf{1}_Q^\top \log(-\omega) - \mathbf{1}_Q^\top \log\big(\theta \odot (1-\theta)\big) \\ &- \log(1+\mathbf{1}_Q^\top\omega) - \log\left(1+\mathbf{1}_Q^\top \frac{\omega}{1-\theta}\right) - \sum_{r<s}\log|\theta_r-\theta_s|.\end{aligned}$$

向量对数和除法均逐元素进行，对数内部保持为正。

5．更新参数并选定机制。为使每次评估均可行，代码优化 $z=(a^\top,w^\top)^\top \in [-12,12]^{2Q}$。对 Q 维向量 v 定义

$$s(v) = \frac{(e^{v_1},\ldots,e^{v_Q},1)^\top}{1+e^{v_1}+\cdots+e^{v_Q}}, \qquad g=s(a), \quad h=s(w),$$

$$\theta(z) = \begin{pmatrix} g_1 \\ g_1+g_2 \\ \vdots \\ g_1+\cdots+g_Q \end{pmatrix}, \qquad \omega(z) = -(1-\theta(z)) \odot (h_1,\ldots,h_Q)^\top.$$

初值 $z^{(0)} = (0_Q^\top, \log(1/Q)\mathbf{1}_Q^\top)^\top$ 对应第 1 步的初值。L-BFGS-B 数值求解

$$\boxed{z^{\mathrm{opt}} \in \operatorname*{arg\,min}_{z\in[-12,12]^{2Q}} f(z)}, \qquad f(z) = F(\theta(z),\omega(z)).$$

每次由 z 得到 θ,ω，重复第 2–4 步，再返回 $f(z),\nabla_z f(z)$。记录归一化目标及其梯度二范数、无穷范数。代码最多迭代 200 次，相对目标停止容差为 10^{-14}，一阶核验要求

$$\|z - \mathrm{clip}_{[-12,12]^{2Q}}(z-\nabla_z f(z))\|_\infty \le 10^{-7}.$$

其中 $\mathrm{clip}_{[-12,12]^{2Q}}$ 表示逐坐标截断；若 $z-\nabla_z f(z)$ 仍在盒内，上式为梯度无穷范数。最终训练机制按误差指标选择。以 j 编号所有可行评估点（含线搜索试探点），取

$$j^\star \in \operatorname*{arg\,min}_{0\le j\le J\,:\,\text{可行}} \mathcal{E}^2(\theta^{(j)},\omega^{(j)}), \qquad (\theta^\star,\omega^\star) = (\theta^{(j^\star)},\omega^{(j^\star)}).$$

由该候选生成 $\bar{C}$，再与独立噪声比较，固定

$$C^\star \in \operatorname*{arg\,min}_{C\in\{\bar{C},I_T\}} \mathcal{E}^2(C).$$

若选中 I_T，置 $P=1$ 并直接使用独立噪声。求解器终点用于报告 f 的收敛；所选机制用于报告 $\mathcal{E}^2$，两者分别记录。在线的 α^t 由前文规则更新，离线只优化噪声参数 θ,ω。

6．按总预算校准一次噪声。取增删邻接，沿用矩阵机制的校准式

$$\varepsilon_\nu = \frac{\nu R^2\,\mathrm{Sens}^2(C^\star)}{2b^2\sigma_{\mathrm{DP}}^2}, \qquad \nu>1,$$

$$\varepsilon_{\mathrm{bound}} = \min_{\nu>1}\left\{\varepsilon_\nu - \frac{\ln\delta+\ln\nu}{\nu-1} + \ln\frac{\nu-1}{\nu}\right\}.$$

记 $a_\nu = \varepsilon + (\ln\delta+\ln\nu)/(\nu-1) - \ln((\nu-1)/\nu)$，采用更紧的 RDP 转换，取

$$\hat{\sigma}^2 = \min_{\nu>1:\,a_\nu>0} \frac{\nu R^2}{2b^2 a_\nu}, \qquad \boxed{\sigma_{\mathrm{DP}}^2 = \hat{\sigma}^2\,\mathrm{Sens}^2(C^\star)}.$$

因此，前述同查询参照下的平均参数误差为

$$\boxed{\frac{1}{pT}\mathbb{E}\|\Delta X\|_F^2 = \eta^2\hat{\sigma}^2\mathcal{E}^2(C^\star)}.$$

重复参与已计入敏感度；预算针对固定配置的一次完整训练，所有基高斯噪声共用上述方差。该方差对应 batch 平均查询，在线加入后不再除以 b。保存 $P,\theta^\star,\omega^\star,\sigma_{\mathrm{DP}}$ 后结束离线计算。

6 在线自适应α 训练

固定 $C=C^\star$、$\theta=\theta^\star$、$\omega=\omega^\star$，初始化

$$u^0 = v^0 = \hat{v}^0 = 0, \qquad d^0 = \mathbf{1}_p, \qquad S^0 = 0 \in \mathbb{R}^{p\times Q}.$$

每轮 $t=1,\dots,T$ 执行以下四步。

1．逐样本缩放裁剪，再平均。

$$g_i^t = \nabla\ell(x^{t-1};z_i), \qquad q^t = \frac{1}{b}\sum_{i=1}^{b}\mathrm{clip}\left(\frac{g_i^t}{d^{t-1}};R\right).$$

2．生成并加入单路相关噪声。

$$\xi^t \sim \mathcal{N}(0,\sigma_{\mathrm{DP}}^2 I_p), \qquad Z^t = \xi^t + S^{t-1}\omega, \qquad \tilde{q}^t = q^t + Z^t.$$

3．选择 α^t，更新参数和二阶状态。以 $M=\mathbf{1}^\top\hat{v}^{t-1}$ 为参照，按前文端点检查与二分规则计算 α^t，得到

$$c^t = \max\{1,\|d^{t-1}\|_\infty\}, \qquad r^t = c^t\left(\frac{d^{t-1}}{c^t}\right)^{\alpha^t}\odot\tilde{q}^t.$$

随后更新

$$u^t = \beta_1 u^{t-1} + (1-\beta_1)\tilde{q}^t, \qquad x^t = x^{t-1} - \eta\frac{u^t}{1-\beta_1^t},$$

$$v^t = \beta_2 v^{t-1} + (1-\beta_2)(r^t)^2, \qquad \hat{v}^t = \frac{v^t}{1-\beta_2^t}, \qquad d^t = \sqrt{\hat{v}^t} + \epsilon_s.$$

新分母从下一轮使用；此步不新增私有查询。

4．更新噪声缓冲区。

$$S^t = S^{t-1}\,\mathrm{Diag}(\theta) + \xi^t\mathbf{1}_Q^\top - \xi^{t-P+1}(\theta^{P-1})^\top.$$

其中 $\theta^{P-1} = (\theta_1^{P-1},\dots,\theta_Q^{P-1})^\top$ 为逐元素幂；$t-P+1\le 0$ 时旧噪声取零，否则由已保存的随机种子重现。向量缓冲占用 $\mathcal{O}(pQ)$ 浮点数，另保存基噪声种子。

7 不限制内存时直接设计C

去掉 P, Q, θ, ω 参数化，直接优化 C 的第一列：

$$C = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ c_1 & 1 & 0 & \cdots & 0 \\ c_2 & c_1 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ c_{T-1} & c_{T-2} & \cdots & c_1 & 1 \end{pmatrix}, \qquad 1 > c_1 > \cdots > c_{T-1} > 0.$$

该约束保证可逆及系数非负递减，继续使用前述敏感度和 $\mathcal{E}^2(C)$。给定 C 后解 $BC = A$ 求 B。初值与障碍项取

$$\boldsymbol{c}^{(0)} = \left(\frac{T-1}{T}, \frac{T-2}{T}, \ldots, \frac{1}{T} \right)^\top,$$

$$\varphi(\boldsymbol{c}) = -\ln(1-c_1) - \ln(c_1 - c_2) - \cdots - \ln(c_{T-2} - c_{T-1}) - \ln c_{T-1}.$$

用 L-BFGS 求解

$$\boxed{\boldsymbol{c}^{\text{opt}} \in \operatorname*{arg\,min}_{1>c_1>\cdots>c_{T-1}>0} \left[\mathcal{E}^2(C) + \lambda \varphi(\boldsymbol{c}) \right]}.$$

每次由 $\boldsymbol{c}^{(j)}$ 生成 $C^{(j)}$，依次求 B、敏感度、目标及梯度；记录目标和梯度范数。最终保留误差最小者，包含独立噪声基线：

$$C^\star \in \operatorname*{arg\,min}_{C \in \{I_T, C^{(0)}, \ldots, C^{(J)}\}} \mathcal{E}^2(C).$$

于是所选同查询误差指标不高于独立噪声基线。按相同预算公式校准 σ_{DP}，在线直接计算

$$Z^t = [(C^\star)^{-1} \Xi]^\top_{t,:}, \qquad \tilde{q}^t = q^t + Z^t.$$

保存历史噪声向量时占用 $\mathcal{O}(pT)$ 内存。查询、α^t 选择及参数与二阶状态更新均沿用上一节。